Université Hassan 1er
École Nationale de Commerce et de Gestion de Settat

FINANCE 3

Risque de crédit : classification à coûts asymétriques

Application au jeu de données *German Credit*





chaimaa mouhib
23003583

Fatima Lamrini
25007655

Encadrant : Mr. Larhlimi

Année universitaire 2026–2027

7 novembre 2026

Résumé

Ce rapport étudie la détection des mauvais risques de crédit à partir de 1 000 dossiers de clients (jeu de données *Statlog German Credit*). Plusieurs modèles de classification sont comparés à une référence par validation croisée. Comme accepter un mauvais risque coûte plus cher que refuser un bon client, le seuil de décision est choisi pour minimiser un coût total, et sa sensibilité à l'hypothèse de coût est analysée. La forêt aléatoire, retenue par validation croisée (AUC de 0,785), voit son coût sur le jeu de test passer de 300 à 184 (soit −39 %) en abaissant le seuil de 0,5 à 0,22.

Table des matières

1 Introduction **2**

2 Données **2**
2.1 Source et contenu . . . 2
2.2 Qualité des données . . . 3
2.3 Répartition de la cible . . . 3
2.4 Variables numériques . . . 4
2.5 Variables catégorielles . . . 5

3 Méthodologie **6**
3.1 Préparation des données . . . 6
3.2 Éviter la fuite d'information . . . 6
3.3 Modèles comparés . . . 6
3.4 Validation croisée et métrique . . . 7
3.5 Sélection du modèle et évaluation . . . 7

4 Résultats de la modélisation **7**
4.1 Comparaison par validation croisée . . . 7
4.2 Effet de la profondeur de l'arbre . . . 8
4.3 Évaluation sur le jeu de test . . . 9
4.4 Matrice de confusion au seuil de 0,5 . . . 9
4.5 Courbe d'apprentissage . . . 10

5 Coûts asymétriques et seuil de décision **11**
5.1 Matrice de coûts et seuil théorique . . . 11
5.2 Choix du seuil optimal . . . 11
5.3 Effet sur les décisions . . . 12
5.4 Analyse de sensibilité . . . 12
5.5 Un autre modèle donnerait-il un meilleur coût ? . . . 13

6 Interprétation **14**
6.1 Importance des variables . . . 14
6.2 Effet du seuil sur deux variables . . . 15
6.3 Exemple : prédiction pour un nouveau client . . . 15

7 Limites et conclusion **16**
7.1 Limites . . . 16
7.2 Conclusion . . . 16
7.3 Pistes d'amélioration . . . 17

1 Introduction

Lorsqu'une banque accorde un prêt, elle prend un risque : si le client ne rembourse pas, elle perd le capital prêté. À l'inverse, refuser un bon client lui fait perdre seulement le revenu des intérêts. Les deux erreurs possibles n'ont donc pas le même coût.

Ce projet cherche à répondre à la question suivante : *à partir des caractéristiques d'un client et de son prêt, peut-on identifier les mauvais risques, et quel seuil de décision retenir lorsque les erreurs ont des coûts différents ?*

Il s'agit d'un problème d'apprentissage supervisé, plus précisément d'une classification binaire : la réponse (bon ou mauvais risque) est connue pour les 1 000 dossiers, et la cible ne prend que deux valeurs. La particularité est la prise en compte de *coûts d'erreur asymétriques*, qui modifie le seuil de décision optimal [3].

La démarche suit les étapes classiques d'un projet de science des données : exploration et visualisation des données (section 2), préparation sans fuite d'information et comparaison de modèles (section 3), évaluation sur un jeu de test (section 4), choix du seuil de décision selon les coûts et analyse de sensibilité (section 5), interprétation du modèle (section 6), puis limites et conclusion (section 7). Le code complet est fourni dans un notebook Google Colab, et les figures de ce rapport en sont issues.

2 Données

2.1 Source et contenu

Le jeu de données est le *Statlog (German Credit Data)* de l'UCI Machine Learning Repository [1]. Il décrit 1 000 clients d'une banque allemande ayant demandé un crédit, au moyen de 20 variables (7 numériques et 13 catégorielles) et d'une cible indiquant si le client est un bon ou un mauvais risque. Les colonnes du fichier d'origine ont été renommées de façon explicite et enregistrées dans un fichier CSV relié au notebook par Google Drive. Les variables sont décrites dans le tableau 1. Les valeurs du type `A11` sont des codes de catégories définis dans la documentation du jeu de données.

Table 1 – Variables du jeu de données.

Variable	Type	Signification
`statut_compte`	catégorielle	Statut du compte courant (A11 à A14)
`duree_mois`	numérique	Durée du crédit, en mois
`historique_credit`	catégorielle	Historique de crédit (A30 à A34)
`objet`	catégorielle	Objet du crédit (10 modalités)
`montant`	numérique	Montant du crédit, en marks allemands (DM)
`epargne`	catégorielle	Épargne et obligations (A61 à A65)
`anciennete_emploi`	catégorielle	Ancienneté dans l'emploi actuel (A71 à A75)
`taux_mensualite`	numérique	Mensualité en % du revenu disponible (1 à 4)
`statut_perso_sexe`	catégorielle	Statut personnel et sexe (A91 à A95)
`autres_debiteurs`	catégorielle	Autres débiteurs ou garants (A101 à A103)
`anciennete_residence`	numérique	Ancienneté de résidence (1 à 4)
`bien`	catégorielle	Bien le plus précieux possédé (A121 à A124)
`age`	numérique	Âge, en années
`autres_credits`	catégorielle	Autres crédits en cours (A141 à A143)
`logement`	catégorielle	Type de logement (A151 à A153)
`nb_credits`	numérique	Nombre de crédits dans cette banque
`emploi`	catégorielle	Type d'emploi (A171 à A174)
`nb_personnes_charge`	numérique	Nombre de personnes à charge
`telephone`	catégorielle	Téléphone (A191, A192)
`travailleur_etranger`	catégorielle	Travailleur étranger (A201, A202)
`risque`	cible	1 = bon risque, 2 = mauvais risque

2.2 Qualité des données

Le fichier ne contient **aucune valeur manquante** et **aucune ligne dupliquée** : l'étape de nettoyage ne supprime donc aucune observation (1 000 lignes avant et après). Les variables numériques ont des échelles très différentes (tableau 2) : le montant varie de 250 à 18 424 DM, la durée de 4 à 72 mois. Le montant moyen (3 271 DM) est nettement supérieur à sa médiane (2 320 DM), ce qui traduit une distribution asymétrique avec quelques crédits très élevés. Ces écarts d'échelle justifient la standardisation des variables numériques avant la modélisation.

Table 2 – Statistiques descriptives des variables numériques (1 000 clients).

Variable	Moyenne	Écart-type	Minimum	Médiane	Maximum
`duree_mois`	20,9	12,1	4	18	72
`montant`	3 271	2 823	250	2 320	18 424
`age`	35,5	11,4	19	33	75
`taux_mensualite`	3,0	1,1	1	3	4
`anciennete_residence`	2,8	1,1	1	3	4
`nb_credits`	1,4	0,6	1	1	4
`nb_personnes_charge`	1,2	0,4	1	1	2

2.3 Répartition de la cible

Les classes sont déséquilibrées (figure 1) : 700 bons risques (70 %) pour 300 mauvais risques (30 %). Deux conséquences en découlent. Le découpage entre entraînement et test doit être *stratifié* pour conserver cette proportion. Et l'exactitude est une métrique trompeuse : accepter tous les clients donnerait déjà 70 % de bonnes décisions. L'évaluation repose donc sur l'AUC, puis sur les coûts.

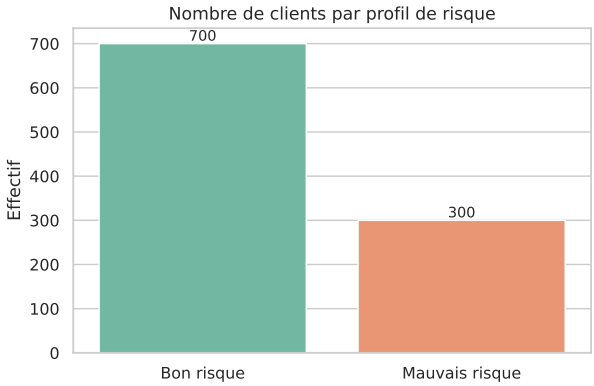


Figure 1 – Répartition des clients selon le profil de risque.

2.4 Variables numériques

Les mauvais risques ont en moyenne des crédits plus longs (24,9 mois contre 19,2) et plus élevés (3 938 DM contre 2 986), et ils sont légèrement plus jeunes (34,0 ans contre 36,2). Cependant, les distributions se chevauchent largement (figure 2) : aucune variable seule ne sépare nettement les deux profils.

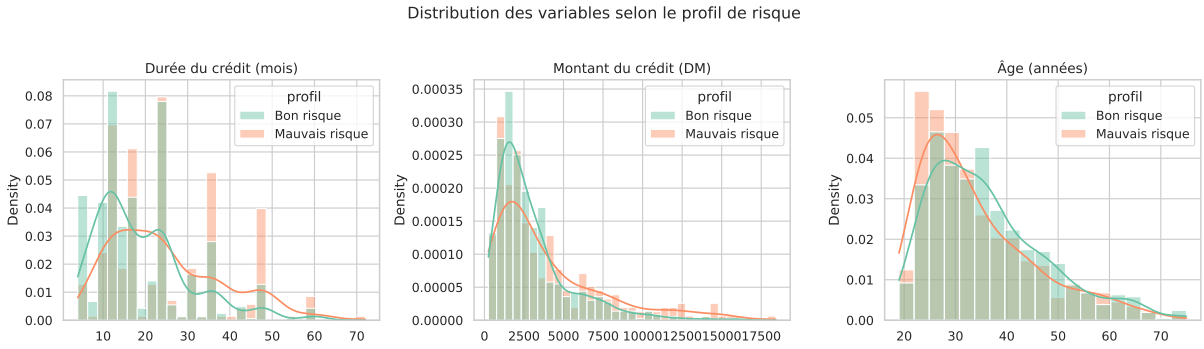


Figure 2 – Distribution de la durée, du montant et de l'âge selon le profil de risque.

La durée et le montant sont liés : la corrélation entre les deux est de 0,62 (figure 3). Les mauvais risques sont un peu plus fréquents parmi les crédits longs et élevés, mais les deux classes restent très mélangées. Les corrélations avec la cible sont faibles (figure 4) : 0,21 pour la durée, 0,15 pour le montant, −0,09 pour l'âge, et pratiquement nulles pour les autres variables numériques. Ces corrélations mesurent seulement des liens linéaires et n'indiquent aucune causalité.

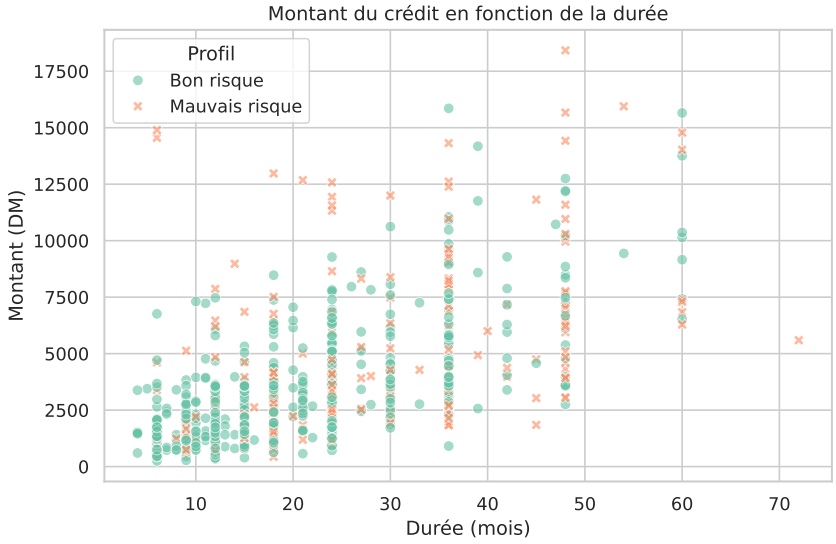


Figure 3 – Montant du crédit en fonction de la durée, selon le profil de risque.

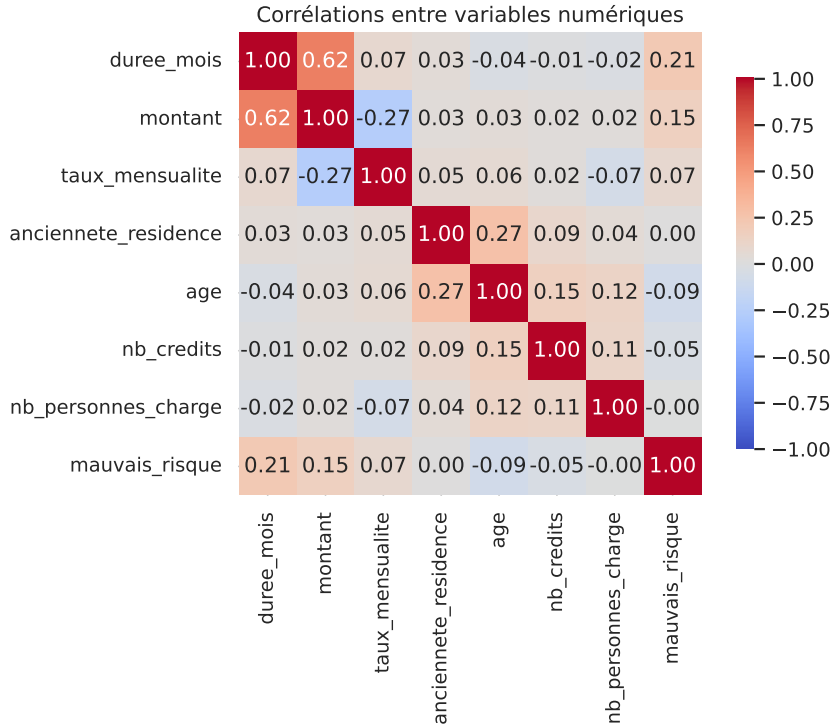


Figure 4 – Corrélations entre les variables numériques et la cible (mauvais risque = 1).

2.5 Variables catégorielles

Les variables catégorielles sont souvent les plus informatives. Le statut du compte courant fait varier la part de mauvais risques de 12 % (pas de compte courant, A14, 394 clients) à 49 % (solde négatif, A11, 274 clients), pour une moyenne de 30 % (figure 5). L'historique de crédit est moins intuitif : les catégories A30 et A31 ont les taux les plus élevés (62 % et 57 %), alors que A34 (compte critique) a le plus bas (17 %). Les deux premières catégories ont de petits effectifs (40 et 49 clients), et cette relation n'a probablement pas d'explication causale simple : les modèles apprendront des associations statistiques, qu'il ne faut pas interpréter comme des causes.

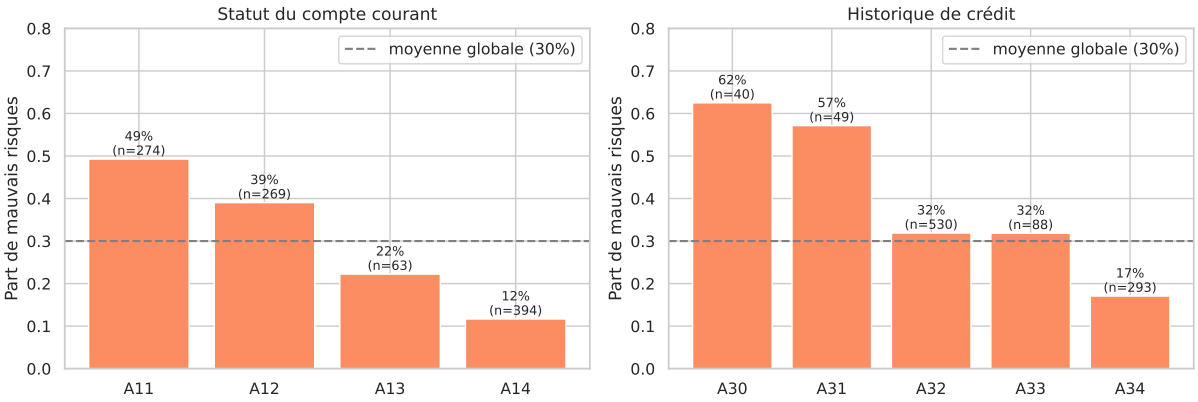


Figure 5 – Part de mauvais risques selon le statut du compte courant et l'historique de crédit.

3 Méthodologie

3.1 Préparation des données

Le fichier CSV est chargé depuis Google Drive dans le notebook. La préparation suit quatre étapes.

1. **Nettoyage.** Les lignes incomplètes ou dupliquées sont supprimées. Aucune ligne n'est concernée ici (section 2).
2. **Séparation des variables.** Les 20 variables forment la matrice d'entrée X. La cible y est recodée : 0 pour un bon risque et 1 pour un mauvais risque, afin que le « mauvais risque » soit la classe positive.
3. **Découpage.** Les données sont séparées en 70 % pour l'entraînement (700 clients) et 30 % pour le test (300 clients). Le découpage est *stratifié* : la part de 30 % de mauvais risques est conservée dans chaque partie. Le jeu de test est mis de côté et n'est utilisé qu'*une seule fois*, pour l'évaluation finale. Une graine aléatoire fixe (42) rend les résultats reproductibles.
4. **Prétraitement.** Les 7 variables numériques sont standardisées (moyenne nulle, écart-type égal à 1). Les 13 variables catégorielles sont transformées par encodage *one-hot* : chaque modalité devient une colonne valant 0 ou 1, car les codes comme `A11` n'ont pas d'ordre numérique. Après encodage, les données comptent environ 61 colonnes.

3.2 Éviter la fuite d'information

Une *fuite d'information* se produit quand des données de test influencent l'entraînement, ce qui rend l'évaluation trop optimiste. Par exemple, standardiser les variables avec la moyenne de *toutes* les observations utiliserait des informations du jeu de test. Pour l'éviter, le prétraitement est placé dans un *pipeline* [2] avec chaque modèle : il est ajusté uniquement sur les données d'entraînement (ou, en validation croisée, uniquement sur les plis d'entraînement), puis appliqué aux données à évaluer. Le seuil de décision (section 5) est lui aussi choisi sans utiliser le jeu de test.

3.3 Modèles comparés

Cinq modèles sont comparés (tableau 3). Tous sont précédés du même prétraitement et implémentés avec scikit-learn [2]. Les hyperparamètres restent à leurs valeurs usuelles : aucun réglage fin n'est effectué, pour garder une comparaison simple.

Table 3 – Modèles comparés.

Modèle	Réglage	Principe
Référence (hasard)	stratégie « prior »	Ignore les variables d'entrée et prédit la proportion de mauvais risques de l'entraînement. Sert de point de comparaison.
Régression logistique	régularisation L_2 par défaut	Modèle linéaire qui estime directement une probabilité.
K plus proches voisins	$k = 5$	Décide d'après les 5 clients les plus ressemblants.
Arbre de décision	profondeur maximale 5	Suite de questions oui/non sur les variables.
Forêt aléatoire	300 arbres	Moyenne de nombreux arbres construits sur des échantillons différents, plus stable qu'un arbre seul.

La référence prédit toujours la même probabilité, quel que soit le client : elle ne peut donc pas classer les clients, et son AUC vaut 0,5, comme le hasard. Un modèle n'a d'intérêt que s'il fait mieux.

3.4 Validation croisée et métrique

Les modèles sont comparés par *validation croisée stratifiée à 5 plis* sur l'entraînement : les 700 clients sont répartis en 5 groupes de 140, chaque modèle est entraîné sur 4 groupes et évalué sur le 5e, et l'opération est répétée 5 fois. On retient la moyenne et l'écart-type des 5 scores. Cette procédure compare les modèles sans utiliser le jeu de test, et l'écart-type mesure la stabilité de chacun.

La métrique est l'*AUC*, l'aire sous la courbe ROC. Soit $s(x)$ la probabilité de mauvais risque donnée par le modèle au client x. L'AUC est la probabilité qu'un mauvais risque tiré au hasard reçoive un score plus élevé qu'un bon client tiré au hasard :

$$\text{AUC} = P\big(s(X_{\text{mauvais}}) > s(X_{\text{bon}})\big). \tag{1}$$

Elle vaut 0,5 pour un classement aléatoire et 1 pour un classement parfait. Elle ne dépend pas du seuil de décision, ce qui convient aux classes déséquilibrées (section 2).

3.5 Sélection du modèle et évaluation

La règle de sélection est fixée *avant* de regarder le test : le modèle retenu est celui qui a le meilleur AUC moyen en validation croisée. Il est ensuite entraîné sur tout l'entraînement et évalué une seule fois sur le jeu de test, avec l'AUC, les courbes ROC, la matrice de confusion et la courbe d'apprentissage. L'effet de la profondeur de l'arbre est étudié à part, avec une courbe de validation. Les coûts, l'analyse de sensibilité et l'interprétation sont présentés dans les sections 5 et 6.

4 Résultats de la modélisation

4.1 Comparaison par validation croisée

Le tableau 4 donne l'AUC de chaque modèle en validation croisée à 5 plis sur l'entraînement, ainsi que son AUC sur le jeu de test. Tous les modèles font mieux que la référence, dont l'AUC vaut 0,5. Le classement en validation croisée est le suivant : forêt aléatoire (0,785), régression logistique (0,764), K plus proches voisins (0,695) et arbre de décision (0,668), comme le montre la figure 6.

Table 4 – AUC en validation croisée (entraînement, moyenne ± écart-type sur 5 plis) et sur le jeu de test.

Modèle	AUC en validation croisée	AUC sur le test
Forêt aléatoire	$0{,}785 \pm 0{,}046$	0,785
Régression logistique	$0{,}764 \pm 0{,}024$	0,801
K plus proches voisins ($k = 5$)	$0{,}695 \pm 0{,}043$	0,752
Arbre de décision (profondeur 5)	$0{,}668 \pm 0{,}050$	0,647
Référence (hasard)	$0{,}500 \pm 0{,}000$	0,500

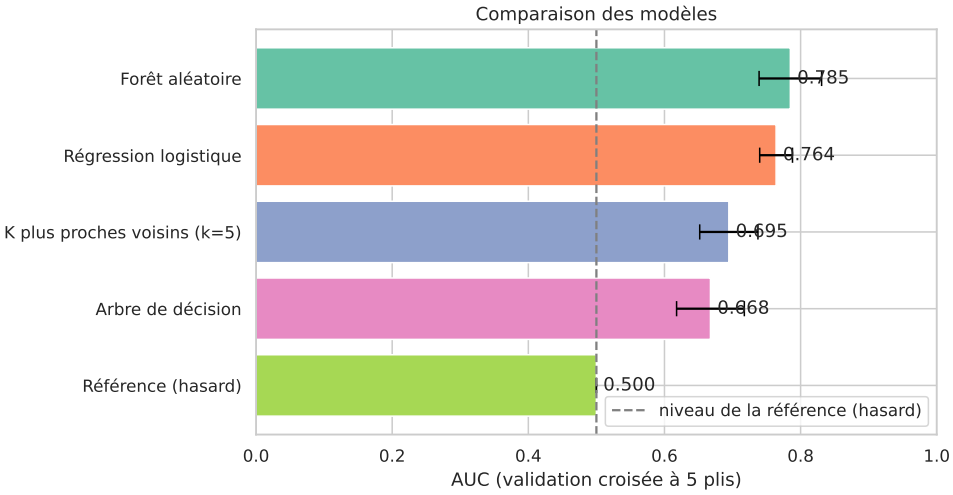


Figure 6 – AUC moyen en validation croisée, avec barres d'erreur (écart-type sur 5 plis).

La forêt aléatoire et la régression logistique sont proches : leur écart (0,021) est inférieur à la variabilité entre plis (écart-type de 0,046 pour la forêt et de 0,024 pour la régression logistique). Conformément à la règle fixée à l'avance (section 3), le modèle retenu est celui qui a le meilleur AUC moyen en validation croisée, soit la **forêt aléatoire**.

4.2 Effet de la profondeur de l'arbre

Un arbre trop profond mémorise les données d'entraînement (surapprentissage), alors qu'un arbre trop simple ne capte pas la structure des données (sous-apprentissage). La figure 7 compare l'AUC d'entraînement et de validation selon la profondeur maximale. L'AUC d'entraînement passe d'environ 0,67 à 1,00 : l'arbre finit par mémoriser les 700 clients. L'AUC de validation fait l'inverse : elle est maximale pour une profondeur de 2 (environ 0,69), puis diminue jusqu'à environ 0,62 pour une profondeur de 15. C'est le signe classique du surapprentissage. Avec la profondeur de 5 utilisée dans la comparaison, l'AUC de validation est d'environ 0,67 : un arbre plus simple ferait un peu mieux, mais resterait loin de la forêt aléatoire.

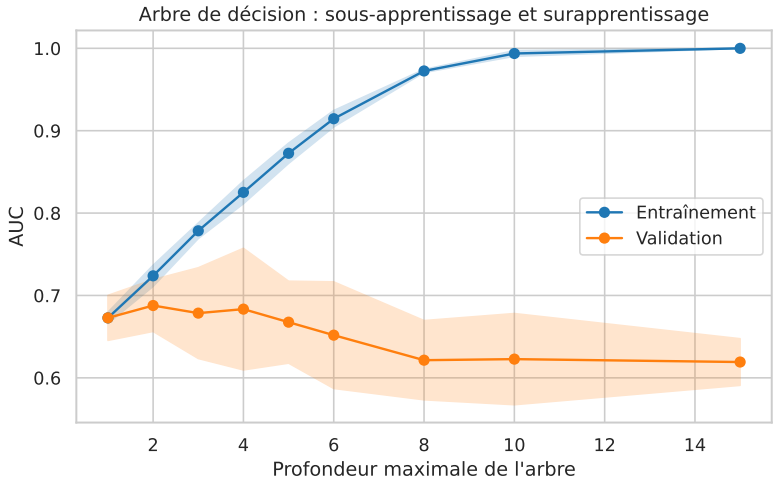


Figure 7 – AUC d'entraînement et de validation d'un arbre de décision selon sa profondeur maximale.

4.3 Évaluation sur le jeu de test

Tous les modèles sont entraînés sur l'ensemble de l'entraînement et évalués une seule fois sur le jeu de test (300 clients). L'AUC de la forêt aléatoire est de 0,785, celle de la régression logistique de 0,801 (dernière colonne du tableau 4 et figure 8). Le classement entre les deux meilleurs modèles s'inverse donc par rapport à la validation croisée, mais l'écart (0,016) est très inférieur à la variabilité observée : avec 300 clients de test, on ne peut pas conclure que l'un est meilleur que l'autre. La forêt aléatoire est conservée, car elle a été choisie par une règle fixée avant de regarder le test : changer de modèle après coup reviendrait à utiliser le test pour choisir, ce qui fausserait l'évaluation.

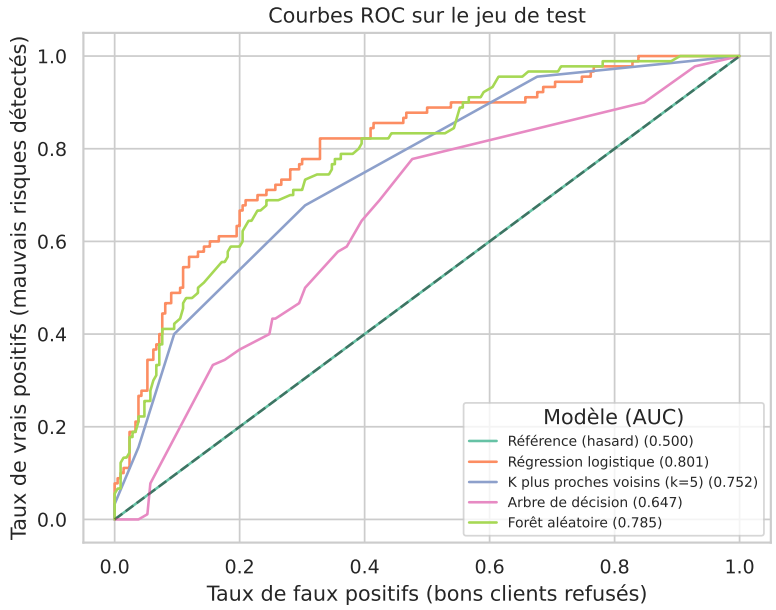


Figure 8 – Courbes ROC des modèles sur le jeu de test (AUC entre parenthèses).

4.4 Matrice de confusion au seuil de 0,5

Au seuil par défaut de 0,5, un client est refusé si la probabilité de mauvais risque donnée par la forêt est supérieure ou égale à 0,5. L'exactitude est de 0,76, mais cette valeur cache un déséquilibre (figure 9). Sur les 300 clients du test (210 bons risques et 90 mauvais risques), le

modèle accepte à tort **57 mauvais risques** (faux négatifs) et refuse à tort **15 bons clients** (faux positifs). Le rappel est de 0,93 pour les bons risques mais de **0,37 seulement** pour les mauvais risques : le modèle n'en détecte que 33 sur 90. La précision de la classe « mauvais risque » est de 0,69. Cette exactitude de 0,76 est donc trompeuse, puisqu'accepter tous les clients donnerait déjà 70 % de bonnes décisions. Au seuil de 0,5, les deux erreurs sont traitées comme si elles étaient aussi graves, ce qui n'est pas le cas pour une banque (section 5).

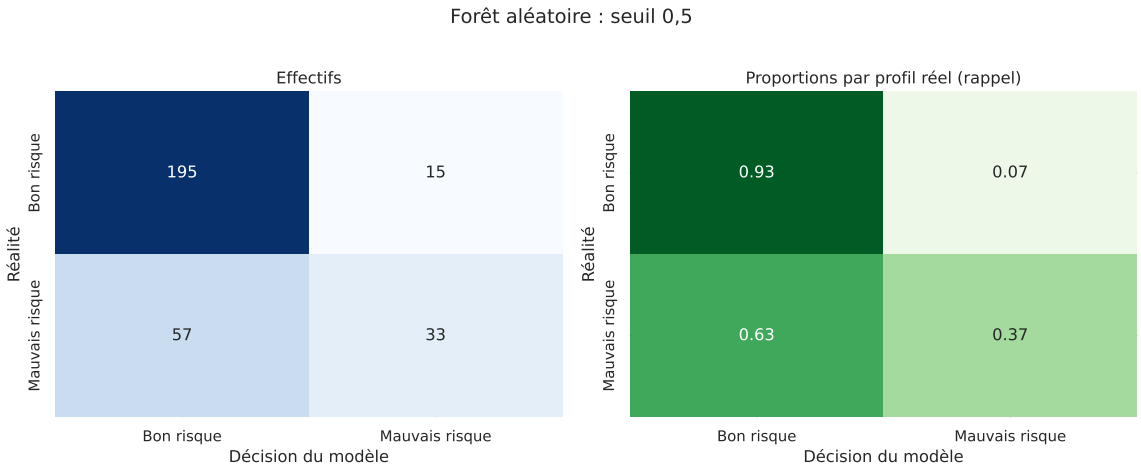


Figure 9 – Matrice de confusion de la forêt aléatoire sur le jeu de test, au seuil de 0,5 (effectifs à gauche, proportions par profil réel à droite).

4.5 Courbe d'apprentissage

La figure 10 montre l'AUC de la forêt selon le nombre d'observations d'entraînement. L'AUC d'entraînement vaut 1,00 quelle que soit la taille de l'échantillon : la forêt mémorise parfaitement les données qu'elle a vues, ce qui est normal pour ce type de modèle. L'AUC de validation augmente avec la taille de l'échantillon, d'environ 0,69 avec une soixantaine de clients à environ 0,78 avec 560 clients, et n'est pas encore stabilisée. L'écart entre les deux courbes indique un surapprentissage, et la hausse continue suggère que davantage de données amélioreraient le modèle. Avec seulement 1 000 dossiers, c'est une limite de ce travail.

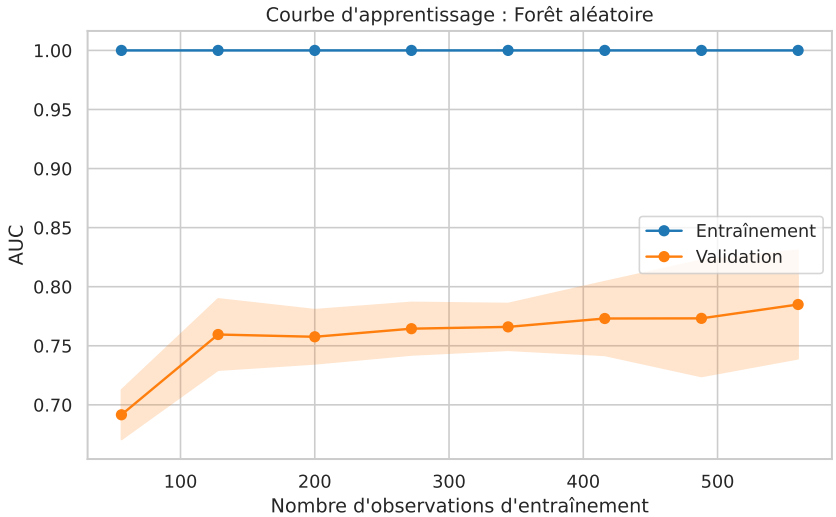


Figure 10 – Courbe d'apprentissage de la forêt aléatoire (AUC selon le nombre d'observations d'entraînement).

5 Coûts asymétriques et seuil de décision

5.1 Matrice de coûts et seuil théorique

Le modèle fournit pour chaque client une probabilité p d'être un mauvais risque, et le client est *refusé* si p est supérieure ou égale à un seuil. Le seuil de 0,5 suppose que les deux erreurs sont aussi graves l'une que l'autre. Or, pour une banque, accepter un mauvais risque (faux négatif) fait perdre le capital prêté, alors que refuser un bon client (faux positif) fait seulement perdre le revenu des intérêts.

Cette asymétrie est modélisée par une matrice de coûts (tableau 5). Nous retenons l'exemple suggéré par l'énoncé du projet : un faux négatif coûte 5, un faux positif coûte 1, et les bonnes décisions coûtent 0. Ce ratio est une **hypothèse** et non une donnée réelle : il traduit seulement l'idée qu'une perte de capital est plus grave qu'une perte d'intérêts. La sous-section 5.4 mesure l'influence de ce choix.

Table 5 – Matrice de coûts retenue (hypothèse).

	Décision : accepter	Décision : refuser
Réalité : bon risque	0	1 (faux positif)
Réalité : mauvais risque	5 (faux négatif)	0

Soit r le ratio c_{FN}/c_{FP}, ici égal à 5. Pour un client de probabilité p, l'accepter coûte en moyenne $c_{FN}\,p$ et le refuser coûte $c_{FP}\,(1-p)$. Il est donc préférable de le refuser lorsque $c_{FP}(1-p) < c_{FN}\,p$, soit

$$p > \frac{c_{FP}}{c_{FP}+c_{FN}} = \frac{1}{1+r}. \tag{2}$$

Pour $r = 5$, ce seuil théorique vaut $1/6 \approx 0{,}167$. Il serait optimal si les probabilités du modèle étaient parfaitement fiables.

5.2 Choix du seuil optimal

Le coût total d'une règle de décision est $C = c_{FN} \times FN + c_{FP} \times FP$, où FN et FP sont les nombres de faux négatifs et de faux positifs. Pour chaque seuil de 0 à 1, on calcule ce coût, puis on retient le seuil qui le minimise. Pour ne pas utiliser le jeu de test, ce seuil est choisi à partir de prédictions obtenues par validation croisée sur l'*entraînement*, puis appliqué au test.

La figure 11 montre le coût moyen par client selon le seuil. Le seuil optimal est de **0,22**, assez proche du seuil théorique de 0,167. L'écart s'explique par le fait que les probabilités d'un modèle ne sont jamais parfaitement calibrées, et par la variabilité d'un échantillon de 700 clients. Sur le jeu de test, le coût total passe de **300** au seuil de 0,5 à **184** au seuil de 0,22, soit une baisse de **39 %** : le coût moyen par client passe de 1,00 à 0,61. Abaisser le seuil rend le modèle plus sévère : il refuse plus de clients, mais laisse passer beaucoup moins de mauvais risques, ce qui compte davantage lorsque ces erreurs coûtent cinq fois plus.

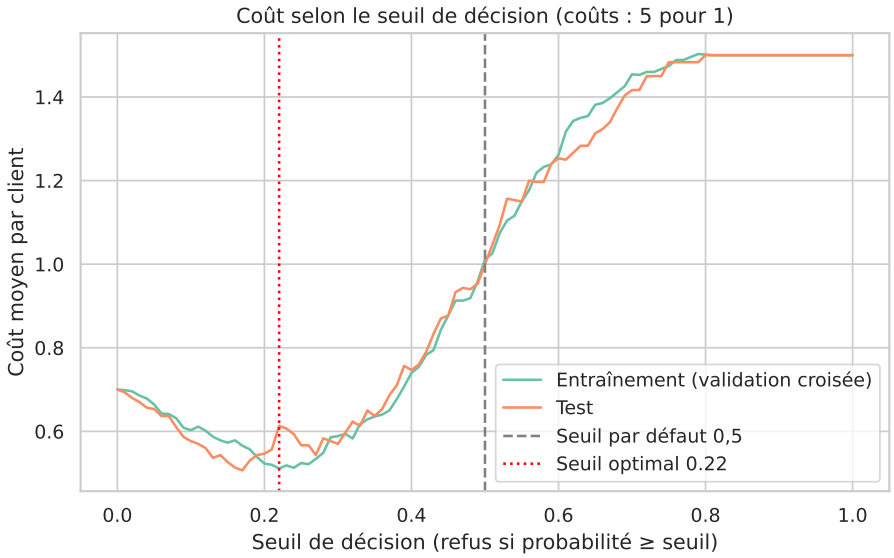


Figure 11 – Coût moyen par client selon le seuil de décision (coûts : 5 pour un faux négatif, 1 pour un faux positif). Le seuil optimal est choisi sur l'entraînement.

5.3 Effet sur les décisions

La figure 12 compare les matrices de confusion sur le jeu de test pour les deux seuils. Au seuil optimal, le modèle détecte **84 %** des mauvais risques, contre 37 % à 0,5 : seulement 14 mauvais risques sont acceptés à tort, contre 57 auparavant. En contrepartie, il refuse **114 bons clients**, contre 15, et l'exactitude chute de 0,76 à 0,57. C'est le compromis voulu : on accepte de refuser beaucoup de bons clients (coût de 1 chacun) pour éviter les mauvais risques (coût de 5 chacun). Ce modèle est donc moins bon en exactitude mais meilleur en coût, ce qui montre que l'exactitude n'est pas la métrique adaptée ici.

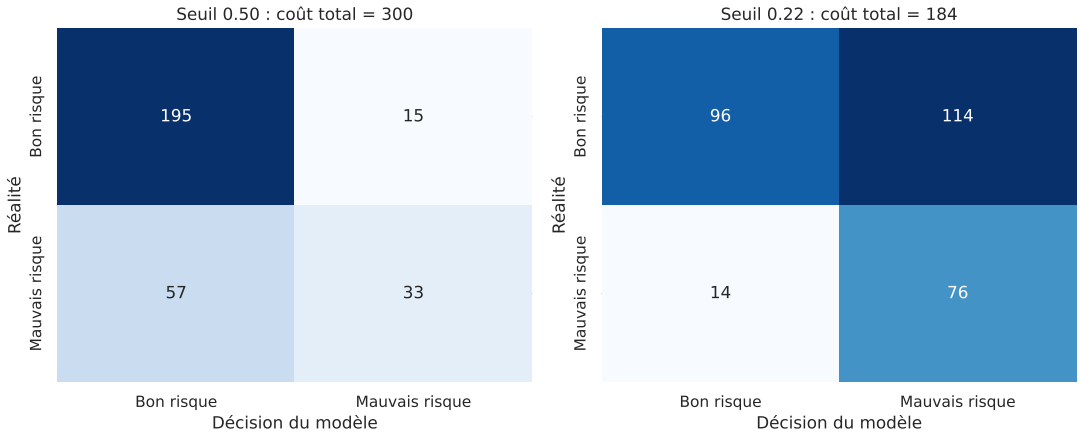


Figure 12 – Matrices de confusion de la forêt aléatoire sur le jeu de test : seuil de 0,5 à gauche, seuil optimal de 0,22 à droite (avec le coût total).

5.4 Analyse de sensibilité

Le ratio de coût est une hypothèse. Le calcul est donc refait pour des ratios de 2, 3, 5 et 10, en recalculant à chaque fois le seuil optimal sur l'entraînement (tableau 6 et figure 13). Le modèle est aussi comparé à deux stratégies sans modèle : accepter tous les clients ou les refuser tous.

Table 6 – Seuil optimal et coût total sur le jeu de test (90 mauvais risques, 210 bons clients) selon le ratio de coût, pour la forêt aléatoire.

Ratio	Seuil théorique	Seuil optimal	Coût à 0,5	Coût au seuil optimal	Tout accepter	Tout refuser
2	0,333	0,37	129	110	180	210
3	0,250	0,26	186	138	270	210
5	0,167	0,22	300	184	450	210
10	0,091	0,09	585	181	900	210

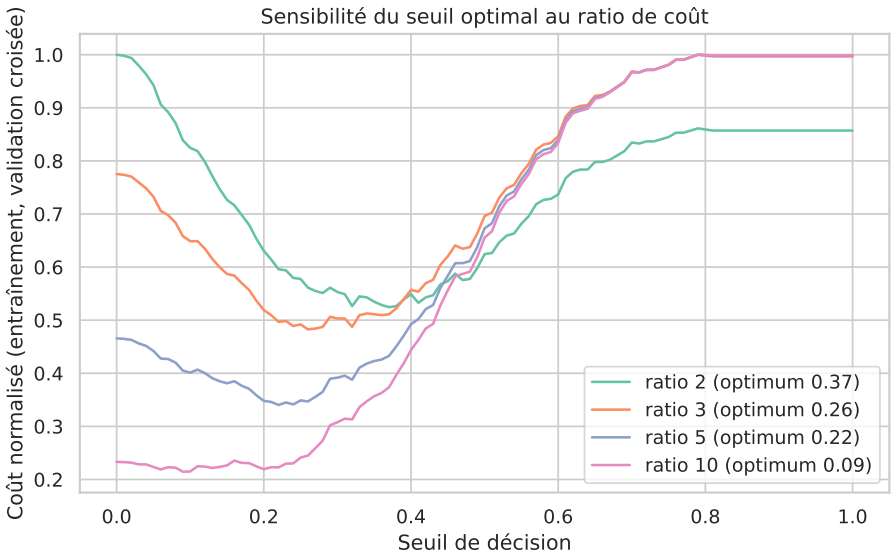


Figure 13 – Coût normalisé selon le seuil, pour différents ratios de coût (entraînement, validation croisée).

Plus le ratio augmente, plus le seuil optimal baisse (0,37 pour un ratio de 2, 0,26 pour 3, 0,22 pour 5 et 0,09 pour 10), et il reste proche du seuil théorique $1/(1+r)$. Le modèle réduit toujours le coût par rapport au seuil de 0,5 : de 129 à 110 pour un ratio de 2, de 186 à 138 pour 3, de 300 à 184 pour 5 et de 585 à 181 pour 10. Le choix du ratio influence donc fortement la décision : c'est l'hypothèse la plus fragile du projet.

La comparaison avec les stratégies sans modèle nuance ce résultat. Le modèle fait toujours mieux que « tout accepter » et que « tout refuser », mais pour un ratio de 10, son coût (181) n'est que 14 % inférieur à celui de « tout refuser » (210). Lorsqu'une erreur sur un mauvais risque coûte très cher, un modèle d'AUC 0,785 n'apporte presque rien de plus que de refuser tous les prêts.

5.5 Un autre modèle donnerait-il un meilleur coût ?

Sur le jeu de test, la régression logistique a un meilleur AUC que la forêt. On vérifie donc si elle donnerait aussi un meilleur coût, en choisissant son seuil de la même façon (sur l'entraînement). Il ne s'agit *pas* d'un moyen de choisir le modèle, puisque le test est consulté : c'est un test de robustesse (tableau 7).

Table 7 – Comparaison des deux meilleurs modèles (ratio de coût de 5, jeu de test).

Modèle	AUC test	Seuil optimal	Coût à 0,5	Coût au seuil optimal
Régression logistique	0,801	0,21	233	166
Forêt aléatoire	0,785	0,22	300	184

La régression logistique obtient un coût de 166, contre 184 pour la forêt : un écart de 18 unités sur un total proche de 180, soit environ 10 %. Cet écart est du même ordre que la variabilité d'un échantillon de 300 clients, et ne suffit pas à affirmer que la régression logistique est meilleure. Les deux modèles conduisent à la **même conclusion** : un seuil autour de 0,2 réduit fortement le coût par rapport au seuil de 0,5. La forêt aléatoire reste le modèle retenu, selon la règle fixée à l'avance, mais la régression logistique, plus simple et plus interprétable, serait un choix tout aussi défendable en pratique.

6 Interprétation

6.1 Importance des variables

La forêt aléatoire permet de mesurer l'importance de chaque variable : la réduction moyenne de l'impureté de Gini qu'elle apporte dans les arbres. Comme les variables catégorielles sont transformées en plusieurs colonnes 0/1, les importances de toutes les colonnes issues d'une même variable d'origine sont additionnées (figure 14).

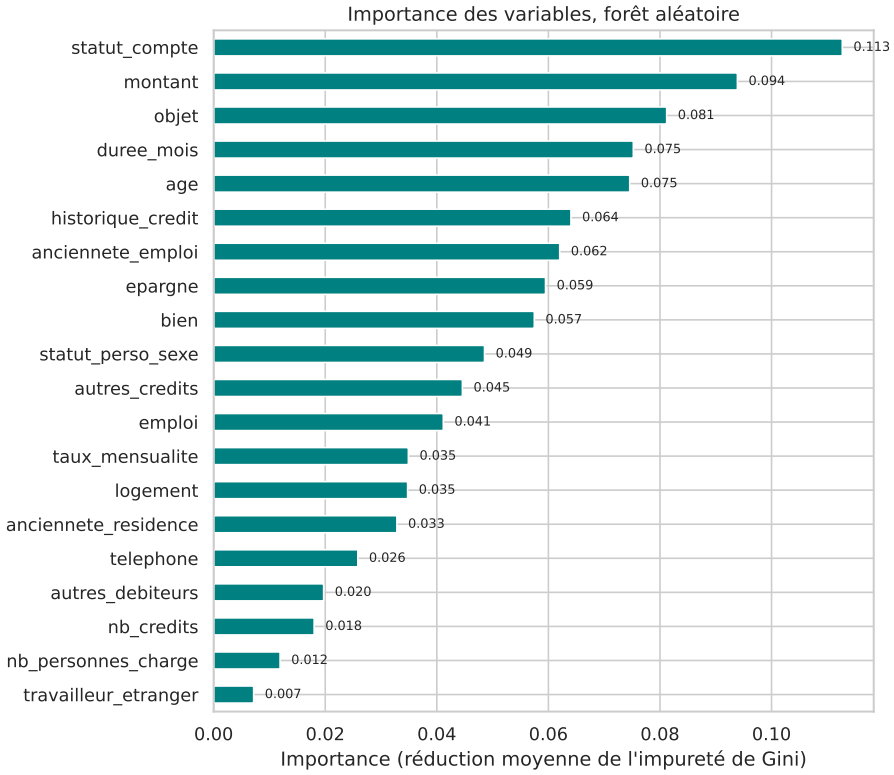


Figure 14 – Importance des 20 variables dans la forêt aléatoire (somme des importances de Gini par variable d'origine).

La variable la plus importante est le **statut du compte courant** (0,113), suivie du **montant** (0,094), de l'**objet du crédit** (0,081), de la **durée** (0,075) et de l'**âge** (0,075), puis de l'historique de crédit (0,064). Ce résultat rejoint l'exploration (section 2) : le statut du compte faisait varier la part de mauvais risques de 12 % à 49 %, et la durée et le montant étaient les variables numériques les plus liées à la cible. À l'inverse, le statut de travailleur étranger (0,007), le nombre de personnes à charge (0,012) et le nombre de crédits (0,018) comptent très peu.

Trois précautions sont nécessaires pour interpréter ces valeurs :

— l'importance de Gini favorise les variables numériques continues (montant, âge) et celles qui ont beaucoup de modalités (objet, 10 modalités) : leur rang peut donc être un peu surestimé ;

— elle indique *combien* une variable sert au modèle, et non *dans quel sens* elle agit ;
— elle ne prouve aucune causalité : le modèle apprend des associations statistiques.

Le jeu de données contient aussi une variable qui mêle le statut personnel et le sexe (importance de 0,049), qui contribue donc aux décisions du modèle. Utiliser une telle variable pour accepter ou refuser un crédit soulève des questions d'équité (et de légalité dans de nombreux pays) que ce travail n'étudie pas ; elles sont reprises dans les limites (section 7).

6.2 Effet du seuil sur deux variables

Pour visualiser l'effet du seuil, un modèle simple (une régression logistique) est entraîné sur deux variables seulement : la durée et le montant. La figure 15 montre la probabilité de mauvais risque en chaque point, avec le seuil de 0,5 et le seuil optimal de 0,22.

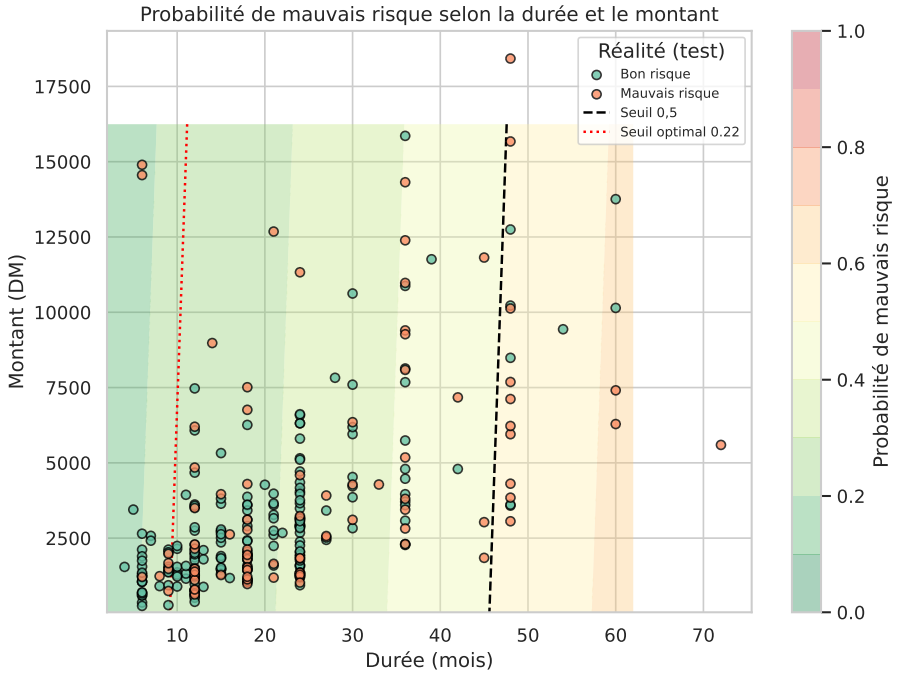


Figure 15 – Probabilité de mauvais risque d'une régression logistique à deux variables (durée et montant). Les points sont les clients du jeu de test.

Les zones de probabilité sont presque verticales : avec ces deux variables, la probabilité dépend surtout de la durée, et le montant ajoute peu. Le seuil de 0,5 se situe vers 45 mois, c'est-à-dire qu'il ne refuserait que des crédits très longs. Le seuil de 0,22 se situe vers 10 mois : il refuserait presque tous les crédits de plus de 10 mois. On retrouve visuellement l'effet de la partie précédente : abaisser le seuil déplace la frontière et rend le modèle beaucoup plus sévère.

Les deux classes restent très mélangées sur toute la carte : deux variables ne suffisent pas à séparer les clients, ce qui justifie l'utilisation des 20 variables. Cette carte est toutefois *illustrative* : le seuil de 0,22 a été optimisé pour la forêt aléatoire, et non pour ce modèle à deux variables, et la figure ne représente donc pas la frontière de décision du modèle retenu.

6.3 Exemple : prédiction pour un nouveau client

Pour illustrer le fonctionnement du modèle, on construit un client fictif (tableau 8) et on calcule sa probabilité d'être un mauvais risque avec la forêt aléatoire.

Table 8 – Quelques caractéristiques du client fictif (les 20 variables sont renseignées dans le notebook).

Variable	Valeur
Montant du crédit	3 000 DM
Durée	24 mois
Âge	35 ans
Statut du compte courant	A11 (solde négatif)
Épargne	A61 (faible)
Historique de crédit	A32

Le modèle attribue à ce client une probabilité d'environ **0,70** d'être un mauvais risque : il serait **refusé** aux deux seuils (0,5 et 0,22). Les clients dont la probabilité se situe entre 0,22 et 0,5 sont ceux dont la décision change selon le seuil : c'est précisément là que la matrice de coûts modifie la décision. Cet exemple est fictif et illustre seulement le fonctionnement du modèle : il ne s'agit pas d'une décision réelle.

7 Limites et conclusion

7.1 Limites

Plusieurs limites doivent être gardées en tête pour interpréter les résultats.

— **Les coûts sont des hypothèses.** La matrice de coûts (5 pour un faux négatif, 1 pour un faux positif) n'est pas issue de données réelles d'une banque. Toute l'analyse du seuil en dépend, comme le montre la sensibilité au ratio (section 5).

— **Un jeu de données petit et ancien.** Le jeu compte 1 000 dossiers, avec des montants en marks allemands. Le jeu de test ne contient que 300 clients (dont 90 mauvais risques) : les coûts mesurés sont donc très variables, et la courbe d'apprentissage n'est pas stabilisée, ce qui indique qu'un échantillon plus grand améliorerait le modèle.

— **Un seul découpage.** Les résultats sur le test dépendent d'un unique découpage entraînement/test (graine 42). Un autre découpage pourrait donner des valeurs différentes, en particulier pour l'ordre entre la forêt aléatoire et la régression logistique, dont les performances sont proches.

— **Pas de réglage fin des modèles.** Les hyperparamètres (nombre d'arbres, profondeur, nombre de voisins) sont à leurs valeurs usuelles, afin de garder une comparaison simple.

— **Des probabilités non calibrées.** Le seuil optimal (0,22) s'écarte du seuil théorique (0,167), et un autre modèle donnerait un autre seuil. Ces probabilités ne sont pas des fréquences de défaut garanties.

— **Équité.** Le jeu contient des variables comme le statut personnel et le sexe, ou le statut de travailleur étranger. Les utiliser pour refuser un crédit soulève des questions éthiques et juridiques que ce travail n'étudie pas.

— **Un biais de sélection possible.** Le jeu décrit des clients dont l'issue du prêt est connue ; il est probable qu'il ne contienne pas les personnes dont la demande a été refusée. C'est une hypothèse, la documentation n'étant pas explicite sur ce point : si elle est exacte, le modèle ne représente pas l'ensemble des demandeurs.

— **Associations et non causes.** Les modèles et les mesures d'importance révèlent des associations statistiques, pas des relations de cause à effet.

7.2 Conclusion

Ce travail visait à identifier les mauvais risques de crédit à partir de 20 variables, et à choisir un seuil de décision adapté à des coûts d'erreur asymétriques. Les principaux résultats sont les suivants.

— Tous les modèles font mieux que la référence (AUC de 0,5). En validation croisée, la forêt aléatoire (0,785) devance la régression logistique (0,764), les K plus proches voisins (0,695) et l'arbre de décision (0,668), mais l'écart entre les deux premiers est dans la marge d'erreur. La forêt a été retenue par une règle fixée à l'avance, sans consulter le jeu de test, où son AUC est de 0,785 (0,801 pour la régression logistique).
— Au seuil par défaut de 0,5, la forêt ne détecte que 37 % des mauvais risques : l'exactitude de 0,76 est trompeuse, puisque les classes sont déséquilibrées et que les erreurs n'ont pas le même coût.
— Avec un coût de 5 pour un mauvais risque accepté et de 1 pour un bon client refusé, le seuil optimal, choisi sur l'entraînement, est de 0,22. Il fait passer le coût du test de 300 à 184 (−39 %) et la détection des mauvais risques à 84 %, au prix de 114 bons clients refusés contre 15.
— Le seuil optimal baisse quand le ratio de coût augmente (0,37 pour 2, 0,09 pour 10). Le ratio choisi est l'hypothèse la plus fragile, et pour un ratio de 10 le modèle ne fait que 14 % mieux que « tout refuser ».
— Le statut du compte courant, le montant, l'objet du crédit, la durée et l'âge sont les variables qui pèsent le plus dans la forêt aléatoire.

L'enseignement principal est méthodologique : le seuil de 0,5, valeur par défaut, n'est pas adapté dès lors que les erreurs ont des coûts différents, et le choix du seuil doit se faire sur des données distinctes du test, en testant sa sensibilité aux hypothèses de coût.

7.3 Pistes d'amélioration

Plusieurs pistes permettraient de prolonger ce travail : régler les hyperparamètres par validation croisée, tester d'autres modèles (par exemple du gradient boosting), calibrer les probabilités, répéter la validation croisée pour estimer la variabilité des coûts, étudier l'équité des décisions selon les groupes de clients et, surtout, obtenir des coûts réalistes auprès d'un professionnel du crédit.

Références

[1] H. Hofmann. *Statlog (German Credit Data)*. UCI Machine Learning Repository, 1994. `https://archive.ics.uci.edu/dataset/144`.

[2] F. Pedregosa *et al.* Scikit-learn : Machine Learning in Python. *Journal of Machine Learning Research*, 12 :2825–2830, 2011.

[3] C. Elkan. The foundations of cost-sensitive learning. *Proceedings of the 17th International Joint Conference on Artificial Intelligence (IJCAI)*, pages 973–978, 2001.